

tp4 Deep Learning

NOUNDJEU NOUBISSIE FRANCK 5GI 21P318 ENSPY

December 2025

1 Introduction

Introduction

La segmentation sémantique constitue une tâche fondamentale en vision par ordinateur, en particulier dans le domaine de l'imagerie médicale où une localisation précise des structures anatomiques est essentielle pour le diagnostic et le suivi clinique. Contrairement aux approches de classification classiques, la segmentation sémantique vise à attribuer une étiquette à chaque pixel d'une image, ce qui nécessite des architectures profondes capables de préserver à la fois le contexte global et les détails spatiaux fins.

Ce travail pratique a pour objectif d'étudier et de mettre en œuvre l'architecture U-Net, largement utilisée pour la segmentation d'images médicales, ainsi que d'analyser les métriques spécifiques à cette tâche, notamment le coefficient de Dice et l'Intersection over Union (IoU). Une attention particulière est également portée aux bonnes pratiques d'ingénierie en apprentissage profond, à travers le suivi des expériences à l'aide de MLflow.

Enfin, ce travail introduit les concepts fondamentaux des convolutions tridimensionnelles (Conv3D), indispensables pour le traitement des données volumétriques telles que les images IRM ou les scanners CT, tout en mettant en évidence les défis computationnels associés à ce type de données.

2 Partie 1 : Segmentation et Bonnes Pratiques MLOps

2.1 Segmentation sémantique et architecture U-Net

Type et dimension de la sortie Contrairement à un modèle de classification classique qui produit un vecteur de probabilités de dimension (N, C) , un modèle de segmentation sémantique génère une prédiction pour chaque pixel de l'image d'entrée. Ainsi, la sortie est un tenseur de dimension :

$$(N, H, W, C)$$

où N est la taille du batch, H et W représentent respectivement la hauteur et la largeur de l'image, et C le nombre de classes. Dans le cas d'une segmentation binaire médicale, on a généralement $C = 1$ avec une activation sigmoïde.

Rôle du chemin décodeur et des connexions de saut L'architecture U-Net est composée d'un chemin contractant (encodeur) et d'un chemin expansif (décodeur). Le rôle principal du décodeur est de restaurer la résolution spatiale de l'image tout en produisant une prédiction précise au niveau des pixels.

Les connexions de saut (*skip connections*) permettent de concaténer les cartes de caractéristiques issues de l'encodeur avec celles du décodeur correspondant. Contrairement aux blocs résiduels de ResNet qui utilisent une addition, U-Net utilise une concaténation afin de préserver les informations spatiales fines perdues lors du sous-échantillonnage. Cette stratégie est essentielle pour obtenir une segmentation précise, notamment dans le domaine médical.

Limites de la cross-entropy et fonction de perte alternative Dans les tâches de segmentation médicale, la classe d'intérêt (par exemple une tumeur) occupe souvent une très petite portion de l'image par rapport au fond. La fonction de perte *categorical cross-entropy* devient alors inadéquate car le modèle peut obtenir une faible perte en prédisant majoritairement le fond.

Une alternative couramment utilisée est la *Dice Loss*, dérivée du coefficient de similarité de Dice, qui met l'accent sur le recouvrement entre la prédiction et la vérité terrain. Cette fonction est plus robuste face au déséquilibre des classes.

2.2 Bonnes pratiques d'ingénierie : suivi des expériences

Convention de nommage des expériences Afin d'assurer une traçabilité claire des expériences, il est recommandé d'adopter une convention de nommage stricte pour les exécutions MLflow. Un exemple de convention est :

Architecture_Optimiseur_FonctionDePerte

Par exemple : UNet2D_Adam_DiceLoss.

Journalisation des métriques personnalisées Les métriques spécifiques à la segmentation, telles que le coefficient de Dice ou l'IoU, ne font pas partie des métriques standards de Keras. Elles doivent être implémentées manuellement puis enregistrées dans MLflow à l'aide de la fonction `log_metric`, ce qui permet une comparaison rigoureuse des performances entre différentes expériences.

3 Partie 2 : Segmentation sémantique sur données médicales

3.1 Coefficient de Dice et Intersection over Union

Coefficient de Dice Le coefficient de similarité de Dice est défini par :

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|}$$

où A représente le masque prédit et B le masque de vérité terrain. Cette métrique mesure le degré de recouvrement entre les deux ensembles et est particulièrement adaptée aux objets de petite taille.

Intersection over Union (IoU) L'Intersection over Union est définie comme :

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|}$$

Cette métrique est plus stricte que le coefficient de Dice et pénalise davantage les erreurs de segmentation, en particulier lorsque la région d'intérêt est petite.

Comparaison entre Dice et IoU Lorsque la cible à segmenter est de petite taille, le coefficient de Dice est généralement plus stable et plus tolérant aux petites erreurs que l'IoU. En revanche, l'IoU est plus sévère et fournit une évaluation plus stricte de la qualité de la segmentation. Dans le contexte médical, le coefficient de Dice est souvent privilégié.

4 Partie 3 : Convolutions 3D et données volumétriques

4.1 Convolution 3D pour données volumétriques

Différence entre Conv2D et Conv3D Une convolution 2D applique un noyau bidimensionnel sur les dimensions spatiales (H, W) de l'image. En revanche, une convolution 3D utilise un noyau tridimensionnel (D, H, W) qui se déplace également le long de la profondeur. Cette approche est indispensable pour exploiter la continuité spatiale présente dans les données volumétriques telles que les images IRM ou les scanners CT.

Contraintes mémoire et compromis d'ingénierie Les couches Conv3D sont très coûteuses en mémoire et en temps de calcul. Pour concevoir une architecture efficace, il est nécessaire de faire des compromis sur la taille des noyaux, le nombre de filtres ou la profondeur des volumes d'entrée. Des stratégies telles que la réduction de la résolution volumique ou l'utilisation de sous-volumes (*patch-based learning*) sont souvent adoptées.

5 Conclusion

Ce travail pratique met en évidence l'importance des architectures spécialisées telles que U-Net pour la segmentation médicale, ainsi que l'utilisation de métriques adaptées comme le coefficient de Dice. Il souligne également les défis posés par les données volumétriques et la nécessité de bonnes pratiques d'ingénierie, notamment le suivi des expériences via MLflow.